

Credit Card Default Prediction Model

Tugas Akhir

Machine Learning Approach for Credit Risk Assessment

S2 Sistem Informasi

Friska Andalusia (202022420003)

Analisa Keputusan Untuk Teknologi Finansial (ABJ)

(Financial Technology Decision Analysis)

1. Latar Belakang Masalah

Signifikansi Industri Perbankan

Default pembayaran kartu kredit merupakan risiko kritis yang mengakibatkan kerugian finansial signifikan. Dengan tingkat default **22%**, diperlukan model prediktif yang akurat untuk identifikasi pelanggan berisiko tinggi.

- **Business Impact:** Mengurangi kerugian finansial dari customer default
- **Risk Management:** Proactive intervention untuk high-risk customers
- **Decision Making:** Data-driven insights untuk approval decisions
- **Efficiency:** Otomatisasi proses identifikasi risiko

Tujuan Penelitian

Tujuan Umum

Mengembangkan model machine learning yang akurat dan robust untuk memprediksi default pembayaran kartu kredit, memungkinkan identifikasi pelanggan berisiko tinggi dan tindakan preventif yang tepat.

Tujuan Spesifik

- Exploratory Data Analysis (EDA) dan karakterisasi dataset
- Data Preprocessing, Feature Engineering & Class Imbalance Handling
- Model Development dengan multiple algorithms
- Comprehensive Model Evaluation & Comparison
- Hyperparameter Tuning untuk optimasi performance
- Model Deployment & Testing dengan new data

Dataset Overview

30,000

Total Records

25

Features + Target

0%

Missing Values

Dataset Overview

Feature Groups

- **Demographic:** LIMIT_BAL, SEX, EDUCATION, MARRIAGE, AGE (5 fitur)
- **Payment Status History:** PAY_1 to PAY_6 (6 fitur) - Status pembayaran 6 bulan terakhir
- **Bill Amount History:** BILL_AMT1 to BILL_AMT6 (6 fitur) - Tagihan bulanan
- **Payment Amount History:** PAY_AMT1 to PAY_AMT6 (6 fitur) - Pembayaran bulanan
- **Target Variable:** default.payment.next.month (0=Non-Default, 1=Default)

Class Distribution Analysis

Non-Default (Class 0)

22,996

77.69% dari total

Default (Class 1)

6,605

22.31% dari total

Imbalance Ratio: 3.48:1

Dataset memiliki significant class imbalance yang memerlukan special handling dalam preprocessing dan model development.

⚠ Stratification dan class weighting sangat penting untuk mencegah model bias terhadap kelas mayoritas.

Data Cleaning Process

Cleaning Step	Rows Removed	Reason
EDUCATION Undocumented Values	742 rows	Values 0, 5, 6 tidak valid per dokumentasi
MARRIAGE Undocumented Values	54 rows	Value 0 tidak valid untuk marriage status
PAY_0 → PAY_1 Renaming	—	Konsistensi naming sequence
Total Data Retention	29,601 rows	97.35%dari original data

Hasil Akhir: Dataset yang bersih dengan excellent data quality, siap untuk modeling.

Feature Engineering

5 New Features Created from Domain Knowledge

- **Payment_Delay_Avg:** Rata-rata status pembayaran 6 bulan terakhir → Disiplin pembayaran overall
- **Bill_to_Limit_Ratio:** $BILL_AMT1 / LIMIT_BAL$ → Tingkat pemanfaatan kredit
- **Payment_to_Bill_Ratio:** $PAY_AMT1 / BILL_AMT1$ → Komitmen membayar tagihan
- **Average_Bill:** Rata-rata tagihan 6 bulan → Pola pengeluaran umum
- **Average_Payment:** Rata-rata pembayaran 6 bulan → Kapasitas ekonomi

Impact: Fitur-fitur baru ini memberikan representasi perilaku pelanggan yang bermakna, meningkatkan kualitas input model secara signifikan.

Dataset Preparation

Training Set (70%)

20,720 samples

Class 0: 16,097 (77.7%)

Class 1: 4,623 (22.3%)

Testing Set (30%)

8,881 samples


Class 0: 6,899 (77.7%)

Class 1: 1,982 (22.3%)

Preprocessing Steps

- **Train-Test Split:** 70:30 dengan stratification (menjaga class distribution)
- **Feature Scaling:** StandardScaler applied hanya pada training set, kemudian ditransfer ke test set (prevent data leakage)
- **Feature Encoding:** Kategorikal features sudah dalam format numerik dari awal

Baseline Models Evaluation



Baseline Models Evaluation

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	0.7722	0.4910	0.5621	0.5241	0.7439
Random Forest	0.8068	0.5826	0.4733	0.5223	0.7667
Gradient Boosting	0.8192	0.6770	0.3628	0.4724	0.7797

Key Insight: Trade-off antara akurasi dan recall. GB memiliki akurasi tertinggi namun recall terendah, mengindikasikan banyak default yang terlewat. LR memiliki recall terbaik namun akurasi lebih rendah.






Hyperparameter Tuning - Random Forest

6 Skenario Kombinasi Parameter untuk Optimasi:

Skenario	max_depth	n_estimators	Accuracy	F1-Score	ROC-AUC
S1 (Conservative)	5	100	0.7573	0.5285	0.7510
S4 (Optimal)	10	150	0.7819	0.5311	0.7770

Skenario Optimal (S4): Balanced parameter configuration menghasilkan performa terbaik dengan recall 0.5535, precision 0.5105, dan ROC-AUC 0.7770.

Result



Best Performance by Metric

Metric	Best Score	Best Scenario
Accuracy	0.8068	S5: D=15, Split=2, Est=100
Precision	0.5826	S5: D=15, Split=2, Est=100
Recall	0.6095	S1: D=5, Split=2, Est=100
F1-Score	0.5311	S4: D=10, Split=5, Est=150
ROC-AUC	0.7770	S4: D=10, Split=5, Est=150

Ensemble Stacking - Simple Version

Accuracy

0.7746

F1-Score

0.5290

ROC-AUC

0.7689

Ensemble Stacking - Simple Version

3 Base Models + Meta-Learner

- **Base Models:** Logistic Regression, Random Forest (S4), Gradient Boosting
- **Meta-Learner:** Logistic Regression (aggregates predictions dari 3 base models)

Stacking memberikan performa yang lebih stabil, menggabungkan kelebihan setiap algoritma

Ensemble Stacking - Advanced Version

Accuracy

0.7831

Recall

0.5474

ROC-AUC

0.7822

Ensemble Stacking - Advanced Version

5 Base Models + Meta-Learner

- **Base Models:** XGBoost, LightGBM, Random Forest, Gradient Boosting, Logistic Regression
- **Meta-Learner:** Logistic Regression dengan L2 regularization ($C=0.1$)
- **Cross-Validation:** 5-Fold StratifiedKFold untuk robust evaluation
- **Result:** **BEST OVERALL PERFORMANCE** dengan balanced metrics

Top Features Analysis

Top 10 Most Important Features

- **PAY_1** - Most recent payment status (0.390 correlation with default)
- **Payment_Delay_Avg** - Average payment delay 6 months (engineered feature)
- **Average_Payment** - Average payment amount (behavioral signal)
- **Bill_to_Limit_Ratio** - Credit utilization ratio (risk indicator)
- **Average_Bill** - Average bill amount (spending pattern)
- **LIMIT_BAL** - Credit limit amount (demographic + behavioral)
- **PAY_2** - Previous payment status (historical indicator)
- **AGE** - Customer age (demographic factor)
- **PAY_AMT1** - Current payment amount (behavior)
- **BILL_AMT1** - Current bill amount (usage)

Model Performance Comparison

Model	Accuracy	Precision	Recall	F1	ROC-AUC	Status
Logistic Regression	0.7722	0.4910	0.5621	0.5241	0.7439	Baseline
Random Forest S4	0.7819	0.5105	0.5535	0.5311	0.7770	Tuned
Stacking Simple	0.7746	0.5166	0.5396	0.5290	0.7689	3 Models
Stacking Advanced	0.7831	0.5229	0.5474	0.5343	0.7822	BEST






✓ Advanced stacking dengan 5 base models mencapai performa terbaik secara keseluruhan.

Selain itu, penelitian ini menghasilkan Ensemble Stacking Advanced dengan StratifiedKFold sebagai solusi optimal juga untuk credit default prediction, mencapai Accuracy 0.8221 / 82% (tertinggi keseluruhan), ROC-AUC 0.7792, F1-Score 0.5275, Recall 0.6075



mengoptimalkan trade-off fundamental antara *overall accuracy, balanced default detection & model robustness*. Kombinasi *systematic hyperparameter tuning (6 skenario), ensemble learning diversity (5 base models), proper cross-validation stratification (respect class imbalance) & comprehensive preprocessing* menghasilkan *model reliable, interpretable, dan production-ready*.

Performance Comparison

Ensemble Stacking - Performance Comparison



Performance Comparison



Baseline models menunjukkan trade-off signifikan antar algoritma dengan gap AUC 3.5% (LR 0.7439 vs GB 0.7797). Ensemble Stacking Advanced mengatasi ini dengan mengintegrasikan 5 base models, menghasilkan AUC tertinggi 0.7822 dengan recall 54.74% dan varians minimal (gap hanya 1.4%), sehingga meningkatkan deteksi default sebesar 50% dibanding baseline dengan performa yang lebih robust dan konsisten untuk production deployment di FinTech system.

FinTech Ecosystem & Strategic Insights

Impact pada Digital Credit Market

- **Risk Mitigation:** Model mencegah kerugian **22.31%** dari transaction volume dengan akurat mengidentifikasi high-risk customers sebelum default terjadi
- **Competitive Advantage:** Real-time default prediction memungkinkan faster decisioning vs traditional manual review (**24-48 jam** → **milliseconds**)
- **Portfolio Optimization:** Stratifikasi risk tier memungkinkan dynamic pricing (interest rates) berdasarkan actual risk profile, bukan demographic assumptions
- **Customer Experience:** Reduce false positives (22% precision) melalui ensemble methods untuk avoid unnecessary credit blocks pada good customers

Kesimpulan & Rekomendasi

Kesimpulan Teknis

- Ensemble Stacking Advanced dengan StratifiedKFold sebagai solusi optimal juga untuk credit default prediction, mencapai Accuracy 0.8221 / 82% (tertinggi keseluruhan), ROC-AUC 0.7792, F1-Score 0.5275, Recall 0.6075
- Payment history features (PAY_1-6) adalah strongest predictors vs demographic features
- Feature engineering (average delay, bill-to-limit ratio) meningkatkan model quality signifikan
- Class imbalance handling melalui stratification dan balanced ensemble methods essential

Rekomendasi Implementasi

- **Production Model:** Deploy Advanced Stacking (5 base models) untuk maximum discriminative power
- **Risk Tiers:** Segment customers berdasarkan probability thresholds untuk differentiated treatment
- **Continuous Monitoring:** Retrain model quarterly dengan new data untuk maintain performance
- **Business Integration:** Integrate dengan credit approval workflow untuk real-time risk assessment

Business KPIs & Deployment Metrics

Default Detection Rate

54.74%

dari actual defaults teridentifikasi

Precision (Risk Alerts)

52.29%

alerts yang truly default

ROC-AUC Score

0.7822

discriminative power

Implementation Strategy

- **Early Warning System:** Trigger proactive interventions (payment reminders, negotiation offers) untuk $\text{PAY_1} \geq 2$ (payment delay)
- **Credit Line Management:** Reduce limit untuk probability > 0.7 , offer restructuring untuk 0.4-0.7 range
- **Collections Priority:** Focus manual collections efforts pada high-probability defaults identified by model
- **Pricing Strategy:** APR adjustment based pada model confidence scores untuk risk-adjusted returns

LINK GITHUB

<https://github.com/friskaa28/Tugas-Besar--AKTF-Friska-Andalusia>

Terima Kasih

Credit Card Default Prediction Analysis

Friska Andalusia | 202022420003

**Analisa Keputusan Untuk Teknologi
Finansial**